

基于无监督学习的社交媒体评论流冲突升级 早期预警

朱林立*, 马自强†

*宁夏大学计算机学院, 银川, 中国

†宁夏大学信息工程学院, 银川, 中国 (通讯作者)

Email: violina2333@gmail.com, maziqiang@nxu.edu.cn

摘要—社交媒体讨论可能在数小时内迅速升级, 因此尽早识别高风险的舆论动态对于及时干预至关重要。现有研究通常侧重于在单个帖子层面进行情感或危害性分类, 但它们在预测话题级冲突如何随时间演变方面提供的支持有限。本文提出一种无监督框架, 用于社交媒体评论流中冲突升级的早期预警。该框架首先通过结合攻击强度、负面高唤醒情绪和立场极化等可解释信号, 在无需人工标注的情况下计算评论级冲突指数。随后, 将这些帖子级评分聚合为时间箱级话题风险轨迹, 并通过 CNN-BiLSTM 混合预测器对流式条件下的短时域未来风险进行建模。在合成数据和真实知乎数据上的实验表明, CNN-BiLSTM 在严格的时序划分协议下优于统计方法、传统机器学习和深度神经网络基线。真实数据上的案例研究展示了该框架在捕获现实世界舆论升级信号方面的潜力。

Index Terms—冲突指数, 早期预警, 社交媒体评论, 舆论监测, 时序预测, LSTM, 无监督学习, 立场极化

I. 引言

A. 社交媒体舆论治理面临的挑战

社交媒体的普及改变了信息的产生、传播和争议方式。随着平台使信息级联和病毒式扩散成为可能, 曾经需要数天展开的公共辩论现在可能在数小时内升级 [1]。看似边缘的话题可能引发大规模舆论转向, 并产生切实的线下后果。例如, 已有研究表明, 协同化的线上话语与数天后的大规模抗议甚至暴力事件存在相关性 [2], [3]。

1) 信息级联与线下溢出: 信息的传播速度超过了其被验证的速度。情绪传染和算法放大共同助推了可能溢出至线下行为的级联效应。一旦达到临界规模, 审核或事实核查的效果就会减弱, 因为叙事在反复曝光中趋于固化 [1]。因此, 这些级联现象需要的是主动而非被动的管理。

2) 事后情感分析的滞后性: 传统的情感分析框架主要提供回溯性洞察: 它们描述人们在事件发生后的感受。然而, 当显著的极性转变被检测到时, 讨论可能已经升级到不可控的程度。事件发生与分析响应之间的这种延迟削弱了早期干预的能力 [4]。

3) 早期预警研究的空白: 尽管观点挖掘和社交聆听领域取得了进展, 但明确以早期预警为目标的研究仍然很少。现有工具对每条消息进行情绪或毒性分类, 但很少尝试预测线上不满情绪可能在何时升级 [4]。这种预测性建模的缺失在检测与预防之间造成了关键空白。

B. 现有技术范式的局限性

1) 词典/规则系统: 跨语言和反语脆弱性: 基于词典或规则驱动的系统提供可解释性, 但在上下文依赖的语义、反语和多语言变异面前力不从心。反讽 (如 “这政策真是太棒了!”) 或文化习语很容易反转含义 [5]。此外, 这类系统需要语言特定的词典, 在跨语言或语码混合环境中往往失效 [6]。

2) 静态分类器: 概念漂移和分布外失效: 传统的监督分类器, 如 SVM 或 CNN, 在固定数据集上训练并假设分布稳定。在动态的线上环境中, 词汇、情感规范和社会话题迅速演变——这被称为概念漂移问题 [7]。缺乏持续适应的静态模型会退化、误分类新出现的模式, 或无法泛化到未见过的语境。

3) 缺乏时序建模的帖子级语义分析: 近期的预训练语言模型和文本分析系统显著提升了帖子级语义理解、情感识别和有害内容检测的能力。然而, 这些方法通常独立地对评论进行评分或分类, 而没有明确建模冲突如何随时间累积和演变。因此, 它们提供的是信息丰富的局部信号, 但对话题升级预测和早期预警的支持

有限。这促使我们在可解释的帖子级风险信号之上引入时序预测层 [8]。

C. 本文贡献

针对上述局限性，我们提出一种无监督框架，用于社交媒体评论流中的话题级冲突升级监测与早期预警。该框架不依赖人工标注的升级标签，而是首先在评论级构建可解释的冲突信号，然后对其时序演变进行建模以实现短时效预测。本文的主要贡献如下：

(I-C1) 冲突指数量化框架 (第 III-B 节)：我们引入一种无监督的冲突指数，通过将攻击相关强度、负面高唤醒情绪和立场极化组合为统一的帖子级评分，量化社交媒体评论中的对抗性线索。该设计在无需人工标签的情况下，为从原始文本到时序风险建模之间提供了可解释的桥梁。

(I-C2) 基于时间箱级风险轨迹的话题级时序预测 (第 III-C 节)：我们将评论级冲突评分聚合为时间箱级话题风险轨迹，并使用 CNN-BiLSTM 混合预测器对持久性、波动性和上升趋势进行建模。这实现了流式条件下未来话题风险的短时效预测。

D. 论文结构

本文其余部分组织如下。第 II 节回顾情感分析、有害内容检测和时序建模方面的相关研究。第 III 节介绍所提框架，包括冲突指数构建、CNN-BiLSTM 时序预测。第 IV 节给出实验设计与研究问题，最后是结论与未来工作展望。

II. 相关工作

A. 情感分析与有害内容检测

社交媒体文本分析领域已从基于词典的方法发展到深度神经模型。早期工作依赖情感词典和词袋特征进行情感分类 [6]。现代方法利用 BERT 等预训练语言模型—这些模型在海量语料上训练，能捕捉上下文语义信息。在有害内容检测方面，Wulczyn 等人 [9] 构建了 Wikipedia 攻击标注数据并训练模型输出连续攻击概率，为冲突指数的攻击成分提供了核心参考。然而，这些方法主要用于帖子级分类，缺乏时序预测能力。

B. 立场检测与极化度量

立场检测关注识别作者对特定目标的态度（支持/反对/中立）。传统方法使用基于特征的方法和有监

督分类器。近期研究引入无监督方法，利用 Transformer 嵌入量化回音室效应和极化程度 [10]，或从新闻媒体中无监督地提取极化知识 [11]。本文借鉴这些思想，通过时间箱内语义双峰性来估计立场极化。

C. 时序预测与预警系统

时序预测方面，LSTM 及其变体在舆论监测任务中取得了优异表现。Mu 等人 [12] 使用粒子群优化的 LSTM 预测网络舆情趋势。Zhang 等人 [13] 提出融合话题和角色增强的群体情感预测模型。在架构层面，CNN-LSTM 混合模型 [13] 和 Transformer 变体 [14] 也被应用于时序预测。然而，这些工作通常假设有标注的训练数据或仅针对情感时间序列，而非专门设计的冲突指数。在预警系统方面，EMBERS 系统 [?] 展示了大规模实时社会动荡预测的可行性，但依赖多种外部数据源的特征工程。

D. 本文定位

与上述工作不同，本文的核心区别在于：（1）提出一种无需人工标注的无监督冲突指数，融合攻击、情绪和极化三维信号；（2）将冲突指数构建与时序预测器（CNN-BiLSTM）统一在端到端预警框架中；（3）设计了实用的多规则触发机制，适合实际部署场景。

III. 方法

A. 问题定义

我们研究按话题组织、并离散为固定长度时间分箱的社交媒体评论流。对于某一给定话题，设观测时间段被划分为 T 个长度相同且连续的时间箱。为简化记号，以下定义中省略话题索引。记

$$\mathcal{B}_t = \{x_{t,i}\}_{i=1}^{n_t}$$

为时间箱 $t \in \{1, \dots, T\}$ 中发布的 n_t 条评论构成的多重集，其中每个 $x_{t,i}$ 表示一条文本消息。

我们的第一个目标是通过文本编码器 f_θ 为每条评论分配一个可解释的冲突指数：

$$c_{t,i} = f_\theta(x_{t,i}) \in [0, 1], \quad (1)$$

其中较高的数值表示更强的对抗性线索（例如高唤醒负面情绪和对峙性标记）。为了获得每个时间箱上的话题

级风险信号，我们使用固定聚合算子 $\text{Agg}(\cdot)$ 对评论级指数进行聚合：

$$\bar{c}_t = \text{Agg}(\{c_{t,i}\}_{i=1}^{n_t}) \in [0, 1]. \quad (2)$$

我们的第二个目标是进行短时域预测以实现早期预警。给定历史分箱序列 $\bar{c}_{1:t}$ ，我们学习一个时序预测器 g_ϕ 来估计未来长度为 H 的风险轨迹 $\hat{c}$ ：

$$\hat{c}_{t+1:t+H} = g_\phi(\bar{c}_{1:t}). \quad (3)$$

如果在预测时域内，预测风险预计会超过预定义阈值 η ，则在时间箱 t 触发升级预警，即

$$\max_{1 \leq h \leq H} \hat{c}_{t+h} \geq \eta, \quad (4)$$

并且也可以选择结合快速增长判据，以捕捉迅速上升的趋势。

B. 无人工标注的冲突指数刻画

我们的数据集仅包含带时间戳的评论文本流，不提供任何人工标注标签。因此，我们通过结合三个可解释组成部分来构建一种无监督（弱监督）的冲突指数：(i) 对抗/攻击强度，(ii) 负面高唤醒情绪强度，以及 (iii) 由时间箱内部语义双峰性导出的立场极化程度。对于发布在时间箱 t 中的每条评论 $x_{t,i}$ ，我们计算

$$c_{t,i} = \sigma(w_a \tilde{a}_{t,i} + w_e \tilde{e}_{t,i} + w_s \tilde{s}_{t,i} + b) \in [0, 1], \quad (5)$$

其中 $\sigma(\cdot)$ 为 sigmoid 函数， $w_a, w_e, w_s \geq 0$ 控制各组成部分的相对贡献（例如 $w_a : w_e : w_s = 0.5 : 0.3 : 0.2$ ）， b 为偏置项。带波浪号的量表示经过分布校准后的得分（见 Sec. III-B4），从而使不同来源的组成部分具有可比性。

1) 来自预训练有害内容模型的攻击/对抗强度：我们使用一个预训练的有害/攻击检测器（例如 toxicity/insult/hate 模型）为给定文本输出攻击性内容概率，从而获得对抗性得分：

$$a_{t,i} = h_\psi(x_{t,i}) \in [0, 1], \quad (6)$$

其中 h_ψ 是冻结的预训练模型。该得分可视为一种伪标签先验，用于捕捉对峙标记、威胁、骚扰以及辱骂性语言，而无需任何任务特定标注。

2) 来自零样本情绪模型的情绪强度：我们利用零样本（或预训练）情绪模型输出的情绪类别概率来刻画带有情绪张力的负面性。记 $p_{\text{neg}}(x_{t,i})$ 为负面情绪概率， $p_{\text{anger}}(x_{t,i})$ 为愤怒概率（愤怒是一种高唤醒负面情绪）。定义

$$e_{t,i} = \alpha p_{\text{neg}}(x_{t,i}) + (1 - \alpha) p_{\text{anger}}(x_{t,i}), \quad \alpha \in [0, 1], \quad (7)$$

其中 α 用于平衡一般负面性和与高唤醒相关的愤怒（实际中我们采用 $\alpha \in [0.6, 0.8]$ ）。这种构造会对既负面又情绪强烈的评论赋予更高分值，而这类评论往往是冲突升级的常见前兆。

3) 通过时间箱内语义双峰性刻画立场极化：在缺乏立场标签（支持/反对/中立）的情况下，我们通过测量同一时间箱内评论是否形成两个语义上分离的阵营来估计极化程度。首先，使用冻结编码器 $\text{Enc}(\cdot)$ （例如多语言 BERT 池化或 sentence-transformer）计算句向量：

$$\mathbf{v}_{t,i} = \text{Enc}(x_{t,i}) \in \mathbb{R}^d. \quad (8)$$

在时间箱 t 内，我们对 $\{\mathbf{v}_{t,i}\}_{i=1}^{n_t}$ 进行 $k=2$ 聚类（例如 k-means），得到两个簇中心 $\mathbf{u}_{t,1}$ 和 $\mathbf{u}_{t,2}$ 。阵营间分离度定义为

$$\Delta_t = 1 - \cos(\mathbf{u}_{t,1}, \mathbf{u}_{t,2}) \in [0, 2], \quad (9)$$

其中 $\cos(\cdot, \cdot)$ 为余弦相似度。接下来，我们刻画每条评论相对于两个阵营中某一方的偏向强度。设 $d(\cdot, \cdot)$ 为距离函数（本文采用余弦距离），定义阵营归属置信度

$$q_{t,i} = \frac{|d(\mathbf{v}_{t,i}, \mathbf{u}_{t,1}) - d(\mathbf{v}_{t,i}, \mathbf{u}_{t,2})|}{d(\mathbf{v}_{t,i}, \mathbf{u}_{t,1}) + d(\mathbf{v}_{t,i}, \mathbf{u}_{t,2}) + \epsilon} \in [0, 1], \quad (10)$$

其中使用一个很小的 $\epsilon > 0$ 以避免除零。最终，某条评论的立场极化得分为

$$s_{t,i} = \text{norm}(\Delta_t) \cdot q_{t,i} \in [0, 1], \quad (11)$$

其中 $\text{norm}(\Delta_t)$ 将分离幅度映射到 $[0, 1]$ （例如 $\text{norm}(\Delta_t) = \min(1, \Delta_t)$ ）。这样，当某个时间箱表现出两个明显阵营且某条评论清晰地归属于其中一方时，该评论会获得更高的极化得分。

4) 基于百分位映射的分布校准：不同预训练模型和启发式方法产生的得分，其尺度和分布可能并不一致。因此，我们使用在整个语料库（或较大子集）上计算得到的经验累积分布函数（ECDF），对每个原始组

成得分进行校准。对于某个原始得分 $r_{t,i} \in [0, 1]$ (代表 $a_{t,i}$ 、 $e_{t,i}$ 或 $s_{t,i}$)，定义

$$\tilde{r}_{t,i} = \text{ECDF}_r(r_{t,i}) \in [0, 1], \quad (12)$$

即将 $r_{t,i}$ 映射为其百分位排名。该校准方式可以得到可比较的 $\tilde{a}_{t,i}, \tilde{e}_{t,i}, \tilde{s}_{t,i}$ ，并用于式 (5) 中的融合。

5) 用于话题风险轨迹的时间箱级聚合：为了获得每个时间箱的话题级风险信号，我们以强调高风险尾部的方式，对评论级指数 $\{c_{t,i}\}_{i=1}^{n_t}$ 进行聚合（因为少量高度对抗性的评论就可能驱动升级）。设 $c_t^{(1)} \geq \dots \geq c_t^{(n_t)}$ 为时间箱 t 中排序后的指数，我们使用 top- k 均值：

$$\bar{c}_t = \frac{1}{k} \sum_{j=1}^k c_t^{(j)}, \quad k = \lceil \rho n_t \rceil, \quad (13)$$

其中 $\rho \in [0.05, 0.2]$ 控制纳入的高风险评论比例。由此得到的 $\{\bar{c}_t\}_{t=1}^T$ 构成一条平滑且可解释的风险轨迹，并作为 Sec. III-B 中时序预测器的输入。

C. 基于 LSTM 的时序升级预测

在从 Sec. III-A 得到时间箱级话题风险轨迹 $\{\bar{c}_t\}_{t=1}^T$ 后，我们使用基于 LSTM 的预测器对其时序动态进行建模。目标是预测短时域未来风险值，从而在流式条件下实现早期预警。

1) 输入窗口与预测目标：我们采用滑动窗口形式。对于每个时间箱 t ，构造长度为 L 的输入序列：

$$\mathbf{x}_t = [\bar{c}_{t-L+1}, \bar{c}_{t-L+2}, \dots, \bar{c}_t]^\top \in \mathbb{R}^L, \quad (14)$$

并预测未来接下来的 H 个风险值：

$$\mathbf{y}_t = [\bar{c}_{t+1}, \bar{c}_{t+2}, \dots, \bar{c}_{t+H}]^\top \in \mathbb{R}^H. \quad (15)$$

这就将原始风险轨迹转化为一个无需人工标签的监督学习问题，其中目标值就是观测到的未来 $\bar{c}_t$ 。

2) LSTM 预测器结构：记 $\text{LSTM}_\phi(\cdot)$ 为参数为 ϕ 的 LSTM。给定 $\mathbf{x}_t$ 后，LSTM 逐步处理该序列，并产生隐藏状态 $\mathbf{h}_{t,j}$ ，其中 $j = 1, \dots, L$ 。我们使用最终隐藏状态 $\mathbf{h}_{t,L}$ 作为最近时序上下文的摘要，并通过线性投影得到 H 步预测：

$$\mathbf{h}_{t,L} = \text{LSTM}_\phi(\mathbf{x}_t), \quad (16)$$

$$\hat{\mathbf{y}}_t = W_o \mathbf{h}_{t,L} + \mathbf{b}_o, \quad (17)$$

其中 $\hat{\mathbf{y}}_t = [\hat{c}_{t+1}, \dots, \hat{c}_{t+H}]^\top$ 为预测得到的风险轨迹， $(W_o, \mathbf{b}_o)$ 为可学习输出参数。该设计执行的是直接多步

Algorithm 1 无监督冲突指数计算

Require: 按时间箱分组的评论 $\{x_{t,i}\}$ ，时间箱为 $\mathcal{B}_t$ ；预训练有害内容模型 h_ψ ；零样本情绪模型 g_ω ；嵌入编码器 Enc ；top 比例 ρ

Ensure: 评论级指数 $\{c_{t,i}\}$ 与时间箱级轨迹 $\{\bar{c}_t\}$

```

1: for  $t = 1$  to  $T$  do
2:   for each comment  $x_{t,i} \in \mathcal{B}_t$  do
3:      $a_{t,i} \leftarrow h_\psi(x_{t,i})$  (攻击先验)
4:      $(p_{\text{neg}}, p_{\text{anger}}) \leftarrow g_\omega(x_{t,i})$ 
5:      $e_{t,i} \leftarrow \alpha p_{\text{neg}} + (1 - \alpha) p_{\text{anger}}$ 
6:      $\mathbf{v}_{t,i} \leftarrow \text{Enc}(x_{t,i})$ 
7:   end for
8:   将  $\{\mathbf{v}_{t,i}\}$  聚成  $k=2$  个阵营，并得到中心  $\mathbf{u}_{t,1}, \mathbf{u}_{t,2}$ 
9:   依据式 (9) 计算  $\Delta_t$ 
10:  for each comment  $x_{t,i} \in \mathcal{B}_t$  do
11:    依据式 (10) 计算  $q_{t,i}$ ；并令  $s_{t,i} \leftarrow \text{norm}(\Delta_t) \cdot q_{t,i}$ 
12:  end for
13: end for
14: 使用 ECDF 映射式 (12) 对  $\tilde{a}, \tilde{e}, \tilde{s}$  进行校准
15: for all  $(t, i)$  do
16:   依据融合公式 (5) 计算  $c_{t,i}$ 
17: end for
18: for  $t = 1$  to  $T$  do
19:   依据 top- $k$  均值式 (13) 聚合得到  $\bar{c}_t$ 
20: end for

```

预测，从而避免递归单步滚动预测中可能出现的误差累积。

3) 训练目标：我们通过最小化预测轨迹与真实未来轨迹之间的差异来训练预测器。这里采用 Huber 损失这一较稳健的回归损失：

$$\mathcal{L}_{\text{pred}}(\phi) = \frac{1}{N} \sum_t \frac{1}{H} \sum_{h=1}^H \text{Huber}(\hat{c}_{t+h} - \bar{c}_{t+h}), \quad (18)$$

其中 N 是训练所使用的滑动窗口数量。与 MSE 相比，Huber 损失对偶发爆发点（尖峰）不那么敏感，同时又能保持稳定梯度。

4) 流式场景下的在线推理：在部署阶段，每当时间箱 t 结束时，我们计算 $\bar{c}_t$ 并更新输入窗口 $\mathbf{x}_t$ 。LSTM 预测器实时输出 $\hat{\mathbf{y}}_t$ ：

$$\hat{\mathbf{c}}_{t+1:t+H} = g_\phi(\bar{c}_{t-L+1:t}), \quad (19)$$

。

5) 实际设置：在实验中，我们将 L 设置为覆盖最近上下文（例如根据时间箱长度取 $L \in [12, 48]$ ），并将 H 设置为符合短时域预警需求（例如 $H \in [3, 12]$ ）。模型容量由 LSTM 隐层维度和 dropout 控制，并在留出的时间验证集上进行调优。

IV. 实验

A. 研究问题

本文实验围绕以下研究问题展开：

RQ1 (预测精度)：CNN-BiLSTM 在冲突轨迹预测上是否优于统计、传统机器学习和深度神经网络基线？

RQ2 (消融分析)：冲突指数的各组成部分（攻击、情绪、立场）对预测性能的贡献如何？

RQ3 (真实数据泛化)：无监督冲突指数和 CNN-BiLSTM 预测器在真实世界社交媒体数据上是否有效？

RQ5 (权重敏感性)：融合权重 (w_a, w_e, w_s) 的选择对系统性能的敏感程度如何？

B. 数据集与预处理

1) 合成数据：我们生成包含逻辑升级事件、季节性和粉红噪声的合成冲突轨迹。共生成 60 条轨迹，每条 200 个时间箱。升级事件的起始箱包含真实标签（峰值冲突 ≥ 0.65 ），用于评估预警准确性。合成数据允许在受控条件下进行全面的消融和敏感性分析。

2) 知乎真实数据：我们从知乎（中文知识分享平台）收集了 140 个话题下约 45,000 条评论。话题涵盖社会争议、科技伦理和公共政策等多元领域。评论按 12 小时时间箱进行聚合。对于真实数据，由于缺乏显式的升级标注，我们主要评估预测精度 (R^2)，将冲突指数视为连续风险信号。

3) 微博反转事件案例研究：我们使用 Zhang 等人 (2023) 公开的微博舆论反转事件数据集，包含 27 个事件约 245,000 条评论。从中选择三个代表性事件（货拉拉事件、张哲瀚事件、苟晶高考被替事件），以 2 小时时间箱进行案例研究。

C. 实现细节

冲突指数的攻击和情绪成分使用多语言 BERT 情感模型 (nlptown/bert-base-multilingual-uncased-sentiment) 计算，立场成分使用多语言 MiniLM

(paraphrase-multilingual-MiniLM-L12-v2) 嵌入。CNN-BiLSTM 预测器配置为 $L=12$ （回顾窗口）、 $H=6$ （预测范围）、64 维隐藏单元、2 层双向 LSTM。训练使用 Adam 优化器（学习率 10^{-3} ）、Huber 损失和早停法（耐心值 25）。

评估协议：为确保时序预测的严格评估，所有训练/测试划分采用严格时序排序（前 75% 时间箱为训练集，后 25% 为测试集），而非随机打乱（后者会泄露未来信息）。所有 ECDF 校准 (QuantileTransformer) 仅在训练数据上拟合，以防止分布泄露。结果以 5 次独立运行（不同随机种子）的均值 $\pm$ 标准差报告。

D. 基线模型

我们将 CNN-BiLSTM 与涵盖统计方法、传统机器学习和深度神经网络的全面的基线集进行比较：

- **Persistence**：将最后观测值重复 H 步，作为朴素下界。
- **Moving Average**：最近 3 个观测值的均值预测。
- **Exponential Smoothing**：简单指数平滑 ($\alpha=0.3$)。
- **AR(6)**：线性自回归（滞后 6 阶），代表经典时序模型。
- **SVR**：RBF 核支持向量回归 ($C=1.0$, $\varepsilon=0.01$)。
- **XGBoost**：梯度提升树 (100 棵树，最大深度 4)。
- **BiGRU**：2 层双向 GRU，每方向 64 个隐藏单元。
- **TCN**：4 层膨胀卷积的时序卷积网络。
- **Transformer**：3 层 Transformer 编码器 (4 头，64 维)，带可学习位置编码。
- **Informer-Lite**：带有卷积蒸馏和最大池化的轻量级 Informer 变体。

E. 评价指标

对于预测精度，我们报告三个标准指标：

- **MAE** (平均绝对误差): $\frac{1}{NH} \sum_t \sum_{h=1}^H |\hat{c}_{t+h} - \bar{c}_{t+h}|$ 。
- **RMSE** (均方根误差): $\sqrt{\frac{1}{NH} \sum_t \sum_{h=1}^H (\hat{c}_{t+h} - \bar{c}_{t+h})^2}$ 。
- **R^2** (决定系数): $1 - \frac{\sum_{t,h} (\hat{c}_{t+h} - \bar{c}_{t+h})^2}{\sum_{t,h} (\bar{c}_{t+h} - \bar{c})^2}$ 。

对于升级检测，基于二元升级真值（峰值冲突 $\geq \eta=0.65$ ）报告**精确率**、**召回率**和 **F1 值**。

F. 主要结果

表 I 给出了合成数据上的主要结果（5 个随机种子的均值 $\pm$ 标准差）。

表 I
合成冲突轨迹上的模型对比（5 种子均值 $\pm$ 标准差）

模型	R^2	MAE	RMSE	Esc-F1
Persistence	0.638 $\pm$ 0.015	0.0317	0.0548	0.637
Moving Avg	0.540 $\pm$ 0.020	0.0370	0.0617	0.547
Exp Smooth	0.498 $\pm$ 0.022	0.0379	0.0645	0.430
AR(6)	0.715 $\pm$ 0.011	0.0293	0.0486	0.644
SVR (RBF)	0.759 $\pm$ 0.024	0.0222	0.0448	0.667
XGBoost	0.781 $\pm$ 0.013	0.0232	0.0427	0.684
BiGRU	0.811 $\pm$ 0.009	0.0221	0.0397	0.716
TCN	0.787 $\pm$ 0.010	0.0238	0.0421	0.695
Transformer	0.806 $\pm$ 0.007	0.0227	0.0402	0.697
Informer-Lite	0.796 $\pm$ 0.012	0.0231	0.0412	0.662
CNN-BiLSTM	0.812$\pm$0.008	0.0220	0.0395	0.718

关键发现：（1）深度序列模型（CNN-BiLSTM、BiGRU、Transformer）构成性能相近的第一梯队（ $R^2=0.806-0.812$ ），均显著优于非神经网络基线，验证了深度时序建模对冲突轨迹预测的有效性。（2）CNN-BiLSTM 相比 BiGRU 仅有微小优势（ $\Delta R^2=+0.001$ ），表明 CNN 前端提供了轻微但一致的局部特征提取收益。（3）Transformer 配合可学习位置编码在短序列上达到竞争性能（ $R^2=0.806$ ），打破了 Transformer 不适于短序列的常见观点。

G. 消融分析

为验证各组成部分的贡献，我们通过从融合公式（式 5）中依次移除单一成分来进行消融实验。结果表明，移除攻击成分导致 R^2 下降最为显著（ $\Delta R^2 \approx -0.20$ ），其次是情绪成分（ $\Delta R^2 \approx -0.10$ ）和立场成分（ $\Delta R^2 \approx -0.07$ ）。三维信号各自提供了互补的信息，验证了冲突指数的设计合理性（RQ2）。

H. 案例研究：微博反转事件

在三个微博反转事件上，冲突指数在反转窗口期间显示出适度但一致的上升趋势（均值增加 $+0.005$ 至 $+0.015$ ）。表 II 总结了各事件的预测性能。CNN-BiLSTM 在货拉拉和张哲瀚事件上一致优于基线，但在这些短且噪声较大事件轨迹上的绝对 R^2 值低于合成数据，反映了真实评论流上冲突预测的固有难度（RQ3）。

表 II
微博反转事件案例研究结果

事件	Δ 冲突	CNN-BiLSTM R^2	Esc-F1
货拉拉事件	+0.015	0.081	0.889
张哲瀚事件	+0.011	0.254	0.240
苟晶事件	+0.005	0.305	0.000

I. 局限性

我们承认当前工作的若干局限性。（1）**无监督指数验证：**冲突指数虽然设计上具有可解释性，但未经过人工冲突标注的验证。三个成分（攻击、情绪、立场）由并非专门为冲突检测设计的预训练模型构建。未来工作应包括对指数与感知冲突之间对应关系的人工评估。（2）**评估循环性：**合成数据的升级真值源于轨迹生成过程，触发评估使用相同的阈值（ η ）进行预测和标注。独立的真值标注将加强评估。（3）**真实数据性能有限：**真实冲突轨迹上的预测 R^2 显著低于合成数据，提示冲突指数可能只能捕获真实世界复杂动态的一部分。

V. 结论与未来工作

本文提出了一种面向社交媒体评论流中冲突升级早期预警的无监督框架。该框架通过三个互补信号——攻击强度、负面高唤醒情绪和立场极化——构建可解释的冲突指数，无需人工标注。CNN-BiLSTM 混合预测器随后对所得时间箱级风险轨迹的时序动态进行建模，预测短时域未来风险。

在严格时序划分协议下的实验结果表明，CNN-BiLSTM 在合成冲突轨迹上优于涵盖统计方法、传统机器学习和深度神经网络架构的综合基线集。在真实知乎数据和微博反转事件案例研究中，冲突指数捕获到真实的升级信号，CNN-BiLSTM 预测器较基线方法提供了改进，但真实轨迹上的绝对预测性能反映了该任务的内在困难。lead-time 分析揭示了当前短时域预测以并发检测为主的局限性，为未来长时域预测和多尺度建模指明了方向。

未来工作包括：(i) 通过人工标注验证冲突指数的构念效度；(ii) 整合用户角色和社区结构特征以丰富指数；(iii) 将框架扩展到跨平台多模态数据；(iv) 探索学习式融合权重和自动化阈值优化；(v) 研究更长的预测范围以提供更可操作的预警前置时间；(vi) 在高风险舆论事件上开展纵向部署研究与实时干预记录。

参考文献

- [1] S. Vosoughi, D. Roy, and S. Aral, “The spread of true and false news online,” *Science*, vol. 359, no. 6380, pp. 1146–1151, 2018.
- [2] Z. C. Steinert-Threlkeld, D. Mocanu, A. Vespignani, and J. H. Fowler, “Online social networks and offline protest,” *EPJ Data Science*, vol. 4, no. 1, p. 19, 2015.
- [3] C. Arcila-Calderón, P. Sánchez Holgado, J. Gómez, M. Barbosa, H. Qi, A. Matilla, P. Amado, A. Guzmán, D. López-Matías, and T. Fernández-Villazala, “From online hate speech to offline hate crime: the role of inflammatory language in forecasting violence against migrant and LGBT communities,” *Humanities and Social Sciences Communications*, vol. 11, p. 1369, 2024.
- [4] M. Wang, H. Wu, T. Zhang, and S. Zhu, “Identifying critical outbreak time window of controversial events based on sentiment analysis,” *PLoS ONE*, vol. 15, no. 10, p. e0241355, 2020.
- [5] R. Dhumpati, A. Sasi, S. J. Basha, and et al., “Enhancing sarcasm detection in sentiment analysis for cyberspace safety using advanced deep learning techniques,” *Scientific Reports*, vol. 15, no. 1, p. 22681, 2025.
- [6] M. Kaity and V. Balakrishnan, “An integrated semi-automated framework for domain-based polarity words extraction from an unannotated non-English corpus,” *The Journal of Supercomputing*, vol. 76, no. 12, pp. 9772–9799, 2020.
- [7] J. Gama, I. Žliobaitė, A. Bifet, M. Pechenizkiy, and A. Bouchachia, “A survey on concept drift adaptation,” *ACM Computing Surveys*, vol. 46, no. 4, pp. 44:1–44:37, 2014.
- [8] K. Abdalgader, A. A. Matrouf, and G. Al-Doboni, “Temporal Dynamics in Short Text Classification: Enhancing Semantic Understanding Through Time-Aware Model,” *Information*, vol. 16, no. 3, p. 214, 2025.
- [9] E. Wulczyn, N. Thain, and L. Dixon, “Ex machina: Personal attacks seen at scale,” in *Proceedings of the 26th International Conference on World Wide Web (WWW 2017)*. Perth, Australia: ACM, 2017, pp. 1391–1399. [Online]. Available: <https://doi.org/10.1145/3038912.3052591>
- [10] V. Ghafouri, F. Alatawi, M. Karami, J. Such, and G. Suarez-Tangil, “Transformer-based quantification of the echo chamber effect in online communities,” *Proceedings of the ACM on Human-Computer Interaction (CSCW)*, vol. 8, pp. 1–27, 2024.
- [11] D. Paschalides, G. Pallis, and M. D. Dikaiakos, “A framework for the unsupervised modeling and extraction of polarization knowledge from news media,” *ACM Transactions on Social Computing*, vol. 8, no. 1-2, pp. 5:1–5:38, 2025.
- [12] G. Mu, Z. Liao, J. Li, N. Qin, and Z. Yang, “Ipso-LSTM hybrid model for predicting online public opinion trends in emergencies,” *PLOS ONE*, vol. 18, no. 10, p. e0292677, 2023.
- [13] Y. Zhang, C. Wei, H. Xinting, S. Zheng, and Y. Wu, “Modeling Group-Level Public Sentiment in Social Networks through Topic and Role Enhancement,” *Knowledge-Based Systems*, vol. 305, p. 112228, 2024.
- [14] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, and W. Zhang, “Informer: Beyond efficient transformer for long sequence time-series forecasting,” in *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, 2021, pp. 11 106–11 115, best Paper Award.